

**PENDETEKSIAN KERUSAKAN CAT PADA BAK DUMP TRUK MENGGUNAKAN
CONVOLUTIONAL NEURAL NETWORK (CNN)**

RISET INFORMATIKA



Oleh:

IMAM MASKURI

20081010074

**PROGRAM STUDI INFORMATIKA
FAKULTAS ILMU KOMPUTER
UNIVERSITAS PEMBANGUNAN NASIONAL "VETERAN"
JAWA TIMUR
2023**

DAFTAR ISI

DAFTAR ISI	2
BAB I.....	4
PENDAHULUAN	4
1.1 Latar Belakang	4
1.2 Rumusan Masalah	5
1.3 Tujuan Penelitian.....	5
1.4 Batasan Masalah.....	6
1.5 Manfaat Penelitian.....	6
BAB II.....	8
TINJAUAN PUSTAKA.....	8
2.1 Penelitian Terdahulu.....	8
2.2 <i>Deep Learning</i>	8
2.3 <i>Convolutional Neural Network (CNN)</i>	9
2.4 <i>Confusion Matrix</i>	10
2.5 <i>Image Preprocessing</i>	10
2.6 Bak Dump Truk.....	11
2.7 <i>Tensorflow</i>	12
2.8 Keras.....	13
2.9 VGG16	13
BAB III	14
METODOLOGI PENELITIAN.....	14
3.1 Waktu dan Tempat Penelitian.....	14
3.2 Bahan dan Alat Penelitian	14
3.3 Diagram Metodologi Penelitian	15
3.4 Data Penelitian	17
3.5 Variabel Penelitian.....	17
3.6 <i>Preprocessing Data</i>	18
3.7 <i>Feature Extraction</i>	19
3.8 Proses Rancangan CNN	19
3.9 Rancangan Pengujian Model.....	20

DAFTAR PUSTAKA.....	22
---------------------	----

BAB I

PENDAHULUAN

1.1 Latar Belakang

Dalam industri transportasi khususnya kendaraan niaga seperti dump truk, kerusakan pada cat bak truk merupakan salah satu permasalahan yang dapat mengakibatkan penurunan kualitas kendaraan dan peningkatan biaya perawatan. Cat yang rusak dapat menjadi salah satu faktor yang mempengaruhi estetika kendaraan dan sangat mempengaruhi penampilan kendaraan secara keseluruhan. Dump truk sering kali digunakan dalam kondisi lingkungan yang buruk seperti di jalan raya atau lokasi konstruksi, yang dapat menyebabkan kerusakan cat. Jika kondisi ini tidak terdeteksi dan segera ditangani, maka dapat menyebabkan kerusakan yang lebih serius pada bak dump truk serta meningkatkan biaya perbaikan dan pemeliharaan.

Deteksi dini kerusakan cat pada bak dump truck penting dilakukan untuk menghindari kerusakan yang lebih parah dan meminimalkan biaya perawatan. Namun, memantau secara manual seluruh permukaan yang dicat pada setiap dump truck dalam armada besar merupakan tugas yang tidak efisien dan memakan waktu. Oleh karena itu, dalam konteks ini, pengembangan sistem otomatis yang mampu mendeteksi kerusakan cat pada bodi dump truck menjadi sangat penting. Penggunaan teknologi yang dapat memproses citra dari sisi samping dump truk dan mengidentifikasi kerusakan cat secara akurat dapat membantu meningkatkan efisiensi pemantauan dan pemeliharaan armada komersial.

Pada penelitian terdahulu milik (van Ruitenbeek & Bhulai, 2022) menggunakan Convolutional Neural Networks (CNNs) untuk mendeteksi kerusakan pada kendaraan dalam konteks layanan mobilitas bersama. Hasilnya menunjukkan bahwa model akhir, terlatih dengan dataset besar, mampu mendeteksi kerusakan kecil dengan akurat dalam berbagai kondisi. Studi ini juga menyoroti tantangan dalam kinerja deteksi akibat pantulan cahaya yang kuat. Model yang terbaik adalah FSSD dengan Darknet-53 dan YOLO v3 dengan Darknet-53, yang menunjukkan hasil yang menjanjikan dalam mendeteksi dan mengklasifikasikan kerusakan kendaraan, dengan kinerja yang sebanding dengan ahli di bidangnya. Namun, model tersebut dipengaruhi oleh pantulan cahaya yang kuat dan mengalami kesulitan dalam membedakan latar belakang dan kerusakan dalam kondisi tertentu.

Berdasarkan penelitian terdahulu metode *convolutional neural network* (CNN) terbukti efektif dalam pengenalan pola pada gambar, terutama dalam hal klasifikasi objek dan deteksi bentuk pada gambar. Penerapan CNN untuk mendeteksi kerusakan cat pada bak dump truk merupakan alternatif yang menjanjikan, memungkinkan deteksi kerusakan cat secara dini dan otomatis tanpa memerlukan pemeriksaan manual yang memakan waktu. Penelitian ini bertujuan untuk mengembangkan sistem berbasis CNN yang mampu mengidentifikasi kerusakan cat pada bak dump truk. Dengan menggunakan metode ini diharapkan dapat memberikan solusi untuk mendeteksi kerusakan cat secara cepat dan akurat, meminimalkan biaya perawatan dan memperpanjang umur kendaraan niaga. Selain itu, penelitian ini juga akan mengeksplorasi parameter terbaik dan algoritma optimasi untuk mendapatkan model CNN yang lebih efektif dalam mendeteksi kerusakan cat bak dump truck.

1.2 Rumusan Masalah

Adapun rumusan masalah yang ingin dicapai dalam penelitian ini, adalah sebagai berikut :

1. Apakah mungkin melakukan pendeteksian kerusakan cat pada bak dump truk menggunakan teknologi Convolutional Neural Network (CNN)?
2. Sejauh mana akurasi dan efisiensi sistem pendeteksian kerusakan ini dalam mengidentifikasi berbagai jenis kerusakan cat pada dump truk yang diproduksi?
3. Bagaimana performa sistem ini dalam menghadapi variasi kondisi pencahayaan dan sudut pengambilan gambar yang mungkin terjadi selama proses produksi?
4. Apakah sistem ini dapat mengenali perbedaan antara kerusakan cat minor yang memerlukan sentuhan akhir dan kerusakan serius yang memerlukan pengecatan ulang?

1.3 Tujuan Penelitian

Adapun tujuan dari penelitian ini yang berdasarkan rumusan masalah, adalah sebagai berikut :

1. Meneliti dan mengembangkan sistem yang mampu mendeteksi kerusakan pada cat bak dump truk menggunakan teknologi Convolutional Neural Network (CNN), memungkinkan pengenalan jenis kerusakan secara cepat dan akurat.

2. Mengukur tingkat akurasi dan efisiensi dari sistem deteksi yang dikembangkan dalam mengidentifikasi berbagai jenis kerusakan cat yang umum terjadi pada dump truk yang diproduksi, seperti goresan, retak, atau kusam.
3. Mengidentifikasi performa sistem deteksi kerusakan cat pada bak dump truk terhadap variasi kondisi pencahayaan yang mungkin terjadi selama proses produksi, serta sudut pengambilan gambar yang berbeda, guna memastikan kemampuan sistem dalam mendeteksi kerusakan dalam berbagai situasi.
4. Mempelajari kemampuan sistem dalam mengenali perbedaan antara kerusakan cat minor yang memerlukan sentuhan akhir serta kerusakan serius yang memerlukan pengecatan ulang, sehingga sistem dapat memberikan rekomendasi tindakan yang tepat kepada pengguna.

1.4 Batasan Masalah

Adapun batasan masalah yang ada pada penelitian ini, sebagai berikut:

1. Kumpulan data yang akan menjadi rujukan dalam penelitian ini berasal dari hasil foto manual di pabrik karoseri yakni PT. Nugraha Karoseri.
2. Metode yang akan digunakan dalam penelitian ini adalah Convolutional Neural Network (CNN).
3. Framework yang digunakan dalam penelitian ini adalah TensorFlow, Keras, dan VGG16.
4. Bahasa pemrograman yang digunakan adalah Python.

1.5 Manfaat Penelitian

Penelitian ini diharapkan dapat memperoleh manfaat baik secara teoritis maupun secara praktis, berikut ini adalah manfaat penelitian secara teoritis dan praktis:

1. Manfaat Teoritis
 - a. Penelitian ini diharapkan akan memberikan wawasan yang mendalam mengenai penggunaan teknologi Convolutional Neural Network (CNN) dalam mendeteksi kerusakan pada objek, khususnya pada analisis citra bak dump truk. Hal ini akan menjadi kontribusi penting dalam pengembangan teknologi deteksi visual menggunakan deep learning.
 - b. Hasil dari penelitian ini diharapkan dapat berperan dalam pengembangan ilmu pengetahuan terutama dalam bidang deep learning. Kontribusi dari implementasi CNN untuk mendeteksi kerusakan cat

pada bak dump truk dapat memperkaya pengetahuan dan pengembangan teknologi deep learning.

2. Manfaat Praktis

- a. Bagi Pendidikan, penelitian ini dapat dijadikan sebagai referensi dan bahan pembelajaran bagi para peneliti, mahasiswa, dan praktisi dalam mengembangkan aplikasi sistem informasi, terutama dalam pengembangan teknologi deteksi kerusakan cat pada kendaraan niaga seperti dump truk.
- b. Bagi mahasiswa, diharapkan hasil dari penelitian ini akan memberikan manfaat langsung bagi masa perkuliahan dengan memberikan pengalaman implementasi teknologi deteksi visual pada citra bak dump truk kepada mahasiswa dan peneliti yang terlibat dalam proses penelitian.

BAB II

TINJAUAN PUSTAKA

2.1 Penelitian Terdahulu

Pada penelitian sebelumnya yang berjudul “*Convolutional Neural Networks for vehicle damage detection*” yang dilakukan oleh (van Ruitenbeek & Bhulai, 2022) menggunakan Convolutional Neural Networks (CNNs) untuk mendeteksi kerusakan pada kendaraan dalam konteks layanan mobilitas bersama. Penelitian ini mengevaluasi berbagai algoritma deep learning, strategi transfer learning, dan teknik pelatihan untuk mengoptimalkan kinerja deteksi. Hasilnya menunjukkan bahwa model akhir, terlatih dengan dataset besar, mampu mendeteksi kerusakan kecil dengan akurat dalam berbagai kondisi. Studi ini juga menyoroti tantangan dalam kinerja deteksi akibat pantulan cahaya yang kuat. Model yang terbaik adalah FSSD dengan Darknet-53 dan YOLO v3 dengan Darknet-53, yang menunjukkan hasil yang menjanjikan dalam mendeteksi dan mengklasifikasikan kerusakan kendaraan, dengan kinerja yang sebanding dengan ahli di bidangnya. Namun, model tersebut dipengaruhi oleh pantulan cahaya yang kuat dan mengalami kesulitan dalam membedakan latar belakang dan kerusakan dalam kondisi tertentu. Kesimpulannya, penelitian ini menunjukkan bahwa deep learning dapat mencapai kinerja yang sebanding dengan manusia dalam deteksi kerusakan kendaraan, namun perlu penelitian lebih lanjut untuk meningkatkan ketangguhan dan konsistensi anotasi. Namun, tidak ada disebutkan informasi spesifik mengenai akurasi persentase yang dicapai oleh model dalam penelitian tersebut.


2.2 Deep Learning

Deep learning merupakan salah satu cabang dari machine learning yang memanfaatkan struktur model komputasi dengan lapisan-lapisan pemrosesan untuk menyajikan representasi data pada berbagai tingkat abstraksi. Metode deep learning ini telah dikembangkan untuk berbagai macam tujuan, seperti mampu mendeteksi objek pada video, identifikasi objek dalam citra, klasifikasi jenis suara, bahkan dalam identifikasi jenis obat-obatan. Kemajuan deep learning memungkinkan untuk menangani data dalam jumlah besar, dimana algoritma backpropagation mampu membimbing mesin untuk menyesuaikan parameter internalnya guna menciptakan representasi pada setiap lapisan berdasarkan informasi dari lapisan sebelumnya.

Dengan penerapan arsitektur deep learning yang tepat, data yang melimpah dan kompleksitas tinggi dapat diolah secara efisien. Di samping itu, deep learning juga berguna dalam pembuatan aplikasi seperti analisis sentimen, penerjemahan bahasa, dan berbagai jenis klasifikasi yang menghasilkan hasil yang tepat. Algoritma deep learning ini juga cocok untuk menangani berbagai jenis masalah, baik yang bersifat supervised, unsupervised, maupun Semi-Supervised Learning, tergantung pada karakteristik dari data yang dihadapi (LeCun et al., 2015).

2.3 Convolutional Neural Network (CNN)

Pada umumnya, *Convolutional Neural Network* (CNN) adalah bagian penting dari jaringan saraf tiruan yang digunakan untuk identifikasi atau klasifikasi objek dalam citra gambar. Komponen utama dalam CNN, yaitu input layer, hidden layers, dan output layer, memiliki peranan krusial dalam proses analisis. Setiap node dalam CNN akan menerima informasi dari input layer, lalu hasilnya diproses melalui hidden layers untuk menghasilkan output. Pengolahan gambar sebagai data melibatkan serangkaian hidden layer dalam CNN, yang bertanggung jawab atas ekstraksi fitur dari gambar untuk kemudian dihitung kemampuan atau performanya (Kadri et al., 2019).



Gambar 2. 1 Struktur Proses Algoritma CNN

Proses pada *Convolutional Neural Network* (CNN), seperti yang terlihat dalam gambar 2.1, melibatkan beberapa tahapan. Tahap awal terdiri dari dua lapisan, yaitu convolutional layers dan pooling layers. Setiap bagian pada convolutional layer diatur berdasarkan feature maps, di mana setiap bagian terhubung ke feature maps pada layer sebelumnya dan mengatur ulang bobot (filter) untuk lapisan selanjutnya.

Convolutional layer didukung oleh fungsi aktivasi, salah satunya adalah algoritma ReLU (*Rectified Linear Unit*). Penggunaan ReLU memiliki kecepatan dalam menjalankan proses, yang membuatnya lebih efisien dalam proses training dan testing. Selain *convolutional* dan *pooling layers*, terdapat juga *fully connected layer*, yang

merupakan bagian dari struktur *Multi-layer Perceptron* (MLP). Layer ini juga menggunakan algoritma ReLU. Fungsi *softmax* digunakan untuk menampilkan hasil akurasi berdasarkan probabilitas dari setiap kelas.

Proses dalam CNN juga melibatkan optimasi, yang bertujuan untuk meningkatkan efisiensi komputasi dari segi waktu dan memori. Metode optimasi seperti Adam dapat digunakan untuk mengatasi jumlah data dan parameter yang besar. Dua parameter utama dalam metode optimasi Adam adalah bobot dan fungsi kerugian (Dendi Maysanjaya, 2020).


2.4 Confusion Matrix

Confusion Matrix adalah model yang sering digunakan untuk menampilkan hasil pengklasifikasian dengan jelas. Ini juga berperan dalam mengevaluasi kinerja berbagai model algoritma. *Confusion matrix* terdiri dari beberapa parameter untuk mengatur kinerja model, seperti F1-Score, Accuracy, Recall, dan Precision (Rahayu & Wahyudi, 2017).

Dalam perhitungan evaluasi kinerja model seperti F1-Score, Accuracy, Recall, dan Precision, terdapat dua parameter utama, yaitu *False Negative* (FN) dan *False Positive* (FP). *False Negative* terjadi ketika sistem mengidentifikasi suatu kelas sebagai negatif, padahal seharusnya kelas tersebut positif. Sebaliknya, *False Positive* terjadi ketika sistem mengidentifikasi suatu kelas sebagai positif, tetapi seharusnya kelas tersebut negatif (Azhari et al., 2021). Parameter ini penting dalam mengevaluasi kinerja model.

2.5 Image Preprocessing

Image processing adalah metode yang mengubah citra menjadi komputasi algoritma komputer, memungkinkan komputer untuk memperoleh informasi yang terkandung dalam citra melalui proses *feature extraction* (S & AsstProfMGokilavani, 2019). Proses teknik *image preprocessing* melibatkan beberapa langkah, sebagaimana diilustrasikan pada Gambar 2.2.



Gambar 2. 2 Proses *Image Preprocessing*

Langkah-langkah Teknik *Image Processing*:

1. Memasukkan Citra

Citra yang akan diproses dimasukkan ke dalam sistem, dapat berasal dari proses scanner atau hasil pemotretan langsung.

2. Analisis dan Manipulasi Citra

Proses ini meliputi berbagai tahapan seperti peningkatan kualitas pada citra, kompresi data citra, dan perancangan pola citra. Pada tahap ini, citra dianalisis dan dimanipulasi untuk meningkatkan kualitasnya atau mengurangi ukuran file agar lebih efisien.

3. *Image Preprocessing*

Setelah tahapan analisis dan manipulasi citra, dilakukan proses *image preprocessing*. Data citra yang telah melalui tahap ini akan diubah kembali menjadi gambar yang siap digunakan dalam proses klasifikasi atau analisis lebih lanjut.

2.6 Bak Dump Truk

Bak dump truk adalah bagian dari truk yang berfungsi sebagai tempat untuk mengangkut material, biasanya material berupa batu, tanah, pasir, atau material lain dalam jumlah besar. Bak dump truk dirancang memiliki kemampuan untuk memuat

muatan dalam jumlah besar dan kemudian dapat dengan mudah dimuat atau diturunkan menggunakan mekanisme hidrolik.

Ciri khas utama dari bak dump truk adalah kemampuannya untuk mengangkat bak menjadi miring ke belakang untuk membongkar muatan. Ini dilakukan dengan menggunakan sistem hidrolik yang mengontrol bagian belakang truk untuk naik dan membuka bak, memungkinkan muatan untuk tumpah keluar ke tempat tujuan seperti gudang atau area konstruksi.

Dump truk memiliki beberapa jenis bak, termasuk bak terbuka dan bak tertutup. Bak terbuka lebih umum digunakan untuk mengangkut material-material yang tidak memerlukan perlindungan terhadap cuaca, seperti tanah atau batu. Sementara itu, bak tertutup biasanya digunakan untuk material yang perlu dilindungi dari elemen-elemen eksternal, seperti bahan kimia atau material yang mudah rusak karena cuaca.

Bak dump truk sering digunakan pada industri konstruksi, pertambangan, pengelolaan limbah, dan sektor transportasi dalam mengangkut material dalam jumlah besar dengan efisiensi yang tinggi. Keberadaannya sangat penting dalam operasi konstruksi dan pemindahan material dalam skala besar.

2.7 *Tensorflow*

TensorFlow adalah sebuah library yang digunakan dalam bidang machine learning sebagai platform end-to-end. Framework ini merupakan library yang luas dan fleksibel. Salah satu fitur utama yang sering dimanfaatkan dari *TensorFlow* adalah penggunaan algoritma *Convolutional Neural Network* (CNN) dalam pengolahan data citra. Selain itu, *TensorFlow* juga terkenal karena mampu untuk berjalan pada berbagai platform tanpa mengorbankan performa dan kecepatan yang signifikan.

TensorFlow dikenal sebagai framework generasi kedua yang dikembangkan dan digunakan secara luas di Google. Pada tanggal 11 Februari, versi 1.0.0 dari *TensorFlow* dirilis, menandai tonggak penting dalam perkembangannya. Salah satu keunggulan dari *TensorFlow* adalah kemampuannya untuk berjalan di berbagai *Central Processing Unit* (CPU) serta menggunakan *Graphics Processing Unit* (GPU) dengan dukungan ekstensi seperti *Compute Unified Device Architecture* (CUDA) dan opsi SYCL pada unit grafis. Hal ini memungkinkan penggunaan GPU untuk melakukan komputasi umum, meningkatkan kecepatan dan efisiensi proses komputasi pada *TensorFlow* (Nabila et al., 2021).

2.8 Keras

Keras adalah library pemrosesan jaringan saraf yang sangat populer dan mudah digunakan dalam bahasa pemrograman Python. Di Keras, pengguna dapat dengan mudah membuat, melatih, dan mengevaluasi model jaringan saraf dengan sedikit kode. Library ini menekankan kesederhanaan dan modularitas, memungkinkan pengguna dengan cepat membuat model jaringan saraf dengan berbagai arsitektur, termasuk jaringan saraf konvolusional (CNN). Salah satu keunggulan Keras adalah tingginya tingkat abstraksi yang dibawanya ke jaringan saraf. (Rochmawati et al., 2021)

Keras memberikan kemudahan dalam membuat model jaringan saraf dengan tingkat kompleksitas yang rendah, cocok untuk pemula yang ingin mempelajari dan memahami konsep dasar pemodelan jaringan saraf. Selain itu, Keras mendukung banyak lapisan, fungsi aktivasi, pengoptimal, dan metrik evaluasi yang memudahkan pengujian konfigurasi model yang berbeda. Kemudahan penggunaan dan fleksibilitas Keras menjadikannya pilihan utama bagi banyak praktisi yang mengimplementasikan jaringan saraf, terutama dalam pemrosesan gambar dan tugas pembelajaran mendalam lainnya.

2.9 VGG16

VGG16 adalah arsitektur jaringan saraf konvolusi (CNN) yang terdiri dari 16 lapisan, termasuk lapisan konvolusi 3x3, diikuti oleh lapisan max-pooling dan beberapa lapisan yang terhubung sepenuhnya. Dikembangkan oleh *Visual Graphics Group* (VGG) Universitas Oxford, arsitektur ini dikenal karena kedalaman dan kesederhanaannya. VGG16 dapat mengekstrak fitur gambar secara bertahap pada abstraksi tingkat tinggi menggunakan sejumlah besar lapisan, memungkinkan Anda mengidentifikasi pola dan fitur kompleks dari gambar. (Syahid, 2021)

Keuntungan utama VGG16 adalah dapat dilatih pada kumpulan data besar seperti ImageNet, dan dengan melakukan penyesuaian di akhir jaringan, VGG16 dapat digunakan sebagai model terlatih untuk berbagai tugas klasifikasi gambar. Namun, kompleksitasnya yang tinggi juga berarti bahwa VGG16 memerlukan sumber daya komputasi dalam jumlah besar, sehingga dapat memperlambat proses pelatihan dan prediksi. Namun demikian, ini adalah salah satu arsitektur paling populer di dunia jaringan saraf konvolusional karena kegunaannya dalam pemrosesan gambar dan pembelajaran transfer.

BAB III

METODOLOGI PENELITIAN

3.1 Waktu dan Tempat Penelitian

Data penelitian yang pertama adalah foto bak dump truk sebagai dataset yang diambil pada tanggal 27 Februari 2024 di perusahaan PT. Nugraha Karoseri untuk mendapatkan dataset foto gambar bak truk yang baru dan normal. Data penelitian kedua yang diambil adalah data foto bak truk yang telah rusak di sekitar jalan raya yang dijumpai saat perjalanan ke kampus maupun kemanapun. Sehingga data yang diperoleh adalah data asli hasil pengambilan secara manual untuk melakukan penelitian.

3.2 Bahan dan Alat Penelitian

Data citra yang akan diolah dalam penelitian ini didapatkan dari melakukan foto secara mandiri di pabrik PT. Nugraha Karoseri dan di sekitar jalan raya yang dilalui untuk mendapatkan dataset terkait. Dataset ini akan menjadi bagian penting dalam penelitian, berperan sebagai bahan dasar untuk melatih dan menguji model yang akan dikembangkan.

Selain dataset citra, bahan yang digunakan dalam penelitian ini juga mencakup referensi dari penelitian-penelitian terdahulu yang terkait dengan computer vision dan deteksi objek. Referensi tersebut akan menjadi landasan teoritis yang mendukung pemahaman mengenai pendekatan, teknik, dan metodologi yang digunakan dalam penelitian terkait. Melalui penelitian-penelitian sebelumnya, akan diperoleh wawasan yang penting untuk dikembangkan lebih lanjut dalam konteks pendeteksian kerusakan cat pada bak dump truk menggunakan teknologi Convolutional Neural Network (CNN).

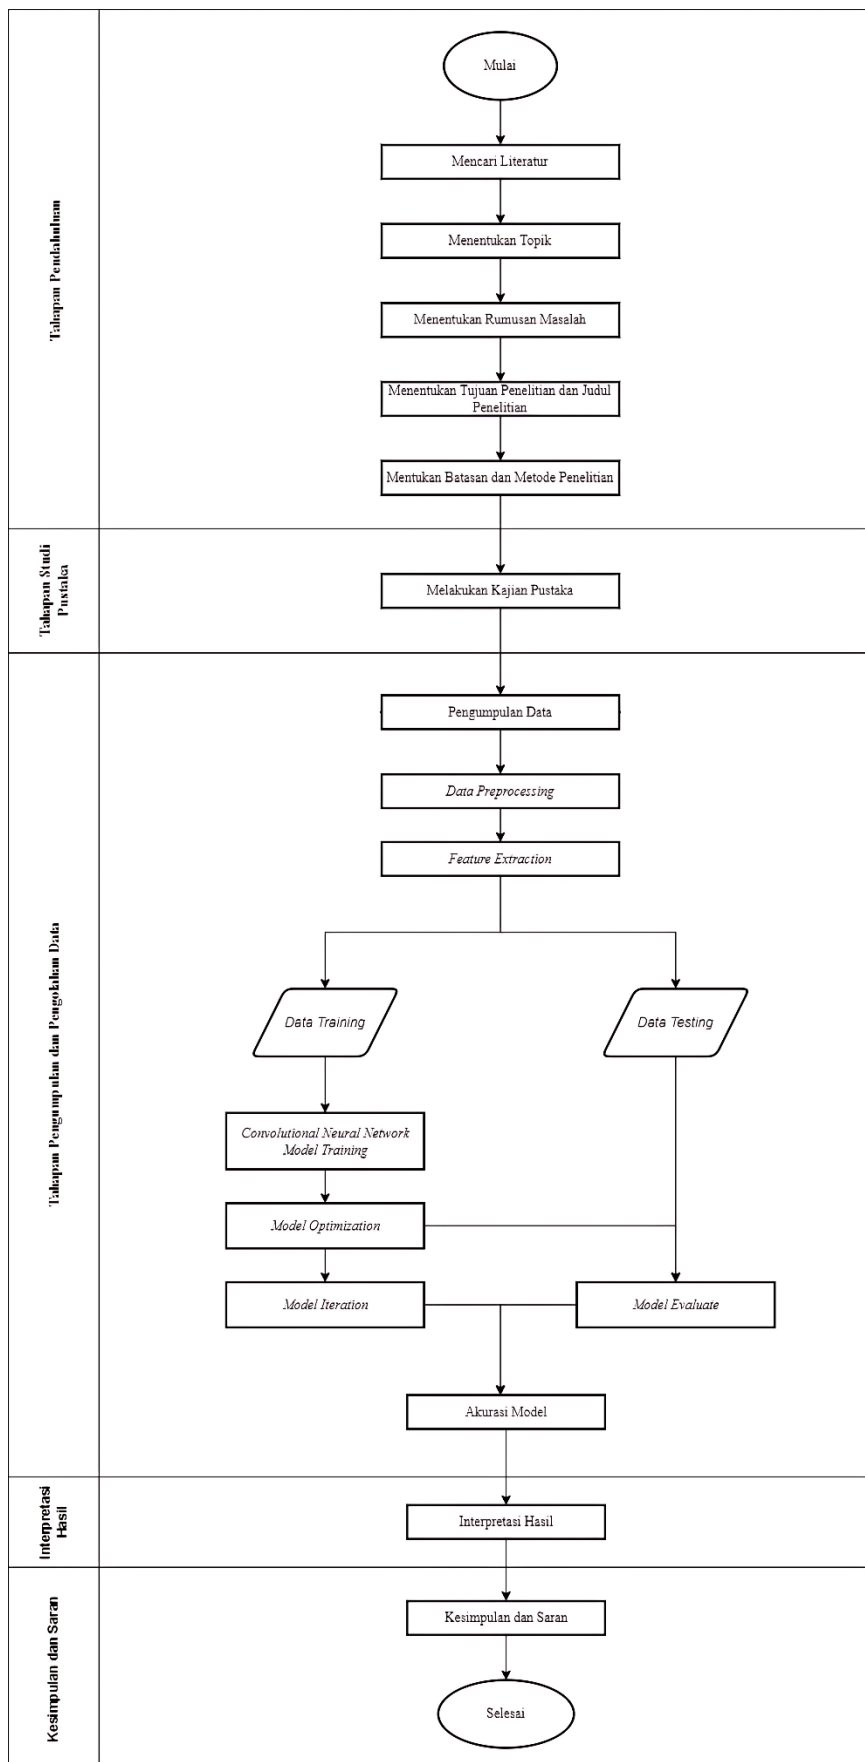
Secara umum alat yang akan digunakan dalam penelitian ini terdiri dari 2 (dua), bagian yaitu:

1. Perangkat Keras (Hardware)
 - a. Processor : AMD Ryzen 3 4300U CPU @ 2.40GHz
 - b. Memori RAM : 12 GB
 - c. Arsitektur : 64-bit operating system
 - d. Perangkat : Mouse dan Keyboard Standard
2. Perangkat Lunak (Software)
 - a. Sistem Operasi : Windows

- b. Pengolahan Data : Jupyter Notebook
- c. Framework : Tensorflow, Keras, dan Flask
- d. Bahasa Pemrograman : Python 3.10

3.3 Diagram Metodologi Penelitian

Berikut ini merupakan flowchart yang menggambarkan alur kegiatan penelitian yang dijalankan, sebagaimana yang diperlihatkan pada gambar 3.1 berikut.



Gambar 3. 1 Diagram Metodologi Penelitian

3.4 Data Penelitian

Jenis data yang digunakan pada penelitian ini merupakan jenis data primer, yang terdiri dari data citra bak truk normal, goresan, retak, dan kusam.



Gambar 3. 2 Dataset Citra Dump Truk

3.5 Variabel Penelitian

Adapun variabel yang digunakan dalam penelitian ini terdiri dari 4 jenis data variabel penelitian, di antaranya sebagai berikut:

Data Citra	Label	Nama Label
	0	Bak normal
	1	Bak tergores

	2	Bak retak
	3	Bak kusam

Tabel 1 Pelabelan Gambar

3.6 Preprocessing Data

Sebelum citra dari sisi dump truk dijalani proses klasifikasi serta ekstraksi fitur, persiapan awal yang harus dilakukan adalah *preprocessing* data. Tujuan utama dari tahapan ini adalah untuk mempersiapkan citra foto sisi dump truk agar dapat masuk ke tahap berikutnya, yakni tahap ekstraksi fitur dengan lebih baik (N. A. Mohammed et al., 2022). Proses *preprocessing* data yang digunakan pada penelitian ini adalah sebagai berikut.

1. Data Balancing

Langkah awal dalam *preprocessing* data adalah melakukan *data balancing* atau penyeimbangan data. Fungsi dari *data balancing* adalah menangani data yang tidak seimbang pada setiap kelas klasifikasi, sehingga hasil klasifikasi tidak cenderung menonjolkan hasil dari kelas yang dominan (Arafat et al., 2019). Dengan demikian, tujuan dari langkah ini adalah untuk memastikan bahwa setiap kelas memiliki representasi yang seimbang dalam proses klasifikasi, menghindari bias yang mungkin timbul akibat ketidakseimbangan tersebut. Proses penyeimbangan data yang digunakan adalah teknik *undersampling*. Teknik ini digunakan untuk mengurangi jumlah sampel dari kelas mayoritas agar seimbang dengan jumlah sampel dari kelas minoritas.

2. Augmentasi Data Citra

Augmentasi citra adalah melakukan proses untuk mengubah data dengan variasi yang baru seperti melakukan rescale, merotasi gambar, mengurangi *mean*, dan lain sebagainya. Dengan acuan utama dimana ukuran citra yang digunakan dalam penelitian ini akan di set menjadi ukuran 150 x 150 piksel. Jika terdapat citra dengan ukuran yang tidak sesuai, maka citra tersebut akan diubah ukurannya untuk disesuaikan dengan ukuran yang ditetapkan. Tujuan dari augmentasi ini adalah untuk memastikan bahwa model yang akan digunakan dapat bekerja dengan optimal, sehingga hasil yang diperoleh menjadi lebih baik dan sesuai dengan harapan penelitian. Dengan ukuran yang konsisten dan telah diatur ulang, proses pelatihan model dapat dilakukan dengan lebih efektif (Oza et al., 2022).

3.7 Feature Extraction

Setelah dilakukan proses *data preprocessing* selanjutnya adalah melakukan feature extraction, feature extraction akan digunakan untuk membedakan setiap warna pada dataset, jika pada dataset citra terdapat warna yang berbeda dari yang lainnya maka akan diubah menjadi RGB (*Red, Green, Blue*), sehingga warna disetiap citra pada dataset memiliki komposisi channel warna yang sama yaitu berada di channel 3 (A. Mohammed & Sajjanhar, 2017). Sehingga dari proses *feature extraction* tersebut didapatkan komposisi layer yaitu 150 x 150 x 3, yang dimana ukuran 150 x 150 merupakan input layer dan ukuran 3 merupakan jumlah channel dari warna yang dimasukkan.

3.8 Proses Rancangan CNN

Langkah selanjutnya melibatkan pembuatan arsitektur model *Convolutional Neural Network* (CNN) dari data yang telah disiapkan. Pada tahap ini, lapisan masukan memiliki ukuran 150 x 150 piksel dengan 3 kanal warna (*Red, Green, Blue*), sehingga komposisi dari lapisan masukan adalah 150 x 150 x 3. Citra akan mengalami proses *feature learning*, dimulai dengan 13 lapisan konvolusi yang masing-masing menggunakan jumlah kernel yang berbeda, diikuti oleh 5 *pooling layer*.

Setelah melewati tahap *feature learning*, citra akan masuk ke dalam *flatten layer*. Tujuan dari lapisan ini adalah untuk mengubah hasil pemrosesan yang terdapat di bagian lapisan pengompresan dari tahap *feature learning* menjadi vektor. Setelah

melalui *flatten layer*, citra akan memasuki tahap kedua dari proses *convolutional neural network*, yaitu tahap klasifikasi.

3.9 Rancangan Pengujian Model

Pada tahap perancangan pengujian model ini, evaluasi dilakukan terhadap model yang akan digunakan dalam penelitian ini, yaitu menggunakan algoritma *Convolutional Neural Network* (CNN) untuk analisis citra dump truk. Dataset yang digunakan terdiri dari citra-citra yang berkaitan dengan kondisi kerusakan pada bak dump truk. Dataset ini akan dibagi menjadi dua bagian, di mana 80% dari dataset akan digunakan sebagai data latih (training), sementara 20% sisanya akan digunakan sebagai data uji (testing). Tujuan dari pengujian model ini adalah untuk mengevaluasi kinerja model yang digunakan dengan menampilkan hasil akurasi dan tingkat loss akurasi. Hasil dari pengujian ini akan direpresentasikan dalam bentuk tabel *confusion matrix* yang akan menjadi metode evaluasi model yang digunakan dalam penelitian. Pada tabel 2 berikut adalah rancangan pengujian model CNN yang akan dilakukan terhadap citra-citra bak dump truk terkait kondisi kerusakan.

	Normal	Tergores	Retak	Kusam
Normal	$P_{(NN)}$	$P_{(TN)}$	$P_{(RN)}$	$P_{(KN)}$
Tergores	$P_{(NT)}$	$P_{(TT)}$	$P_{(RT)}$	$P_{(KT)}$
Retak	$P_{(NR)}$	$P_{(TR)}$	$P_{(RR)}$	$P_{(KR)}$
Kusam	$P_{(NK)}$	$P_{(TK)}$	$P_{(RK)}$	$P_{(KK)}$

Tabel 2 Rancangan Pengujian Model

Setelah didapatkan hasil prediksi kelas untuk kelompok kerusakan bak dump truk, maka selanjutnya dapat melakukan perhitungan untuk mendapatkan hasil akurasi dengan menggunakan rumus berikut:

$$Accuracy = \left(\frac{TP + TN}{TP + TN + FP + FN} \right) \times 100\%$$

Keterangan :

- TP = True Positive
- TN = True Negative
- FP = False Positive
- FN = False Negative

DAFTAR PUSTAKA

- Arafat, M. Y., Hoque, S., Xu, S., & Farid, D. M. (2019). Advanced Data Balancing Method with SVM Decision Boundary and Bagging. *2019 IEEE Asia-Pacific Conference on Computer Science and Data Engineering (CSDE)*, 1–7.
<https://doi.org/10.1109/CSDE48274.2019.9162349>
- Azhari, M., Situmorang, Z., & Rosnelly, R. (2021). Perbandingan Akurasi, Recall, dan Presisi Klasifikasi pada Algoritma C4.5, Random Forest, SVM dan Naive Bayes. *Jurnal Media Informatika Budidarma*, 5(2), 640. <https://doi.org/10.30865/mib.v5i2.2937>
- Dendi Maysanjaya, I. M. (2020). Klasifikasi Pneumonia pada Citra X-rays Paru-paru dengan Convolutional Neural Network (Classification of Pneumonia Based on Lung X-rays Images using Convolutional Neural Network). *Jurnal Nasional Teknik Elektro Dan Teknologi Informasi* |, 9(2), 190.
<https://garuda.kemdikbud.go.id/documents/detail/2807288>
- Kadri, A., Sharma, K., & Chauhan, N. (2019). Age and Gender Detection using Deep Learning Models. *International Journal of Computer Sciences and Engineering*, 7, 671–676. <https://doi.org/10.26438/ijcse/v7i4.671676>
- LeCun, Y., Bengio, Y., & Hinton, G. (2015). Deep learning. *Nature*, 521(7553), 436–444.
<https://doi.org/10.1038/nature14539>
- Mohammed, A., & Sajjanhar, A. (2017). Investigation of Gender and Race Classification for Different Color Models. 1–8. <https://doi.org/10.1109/DICTA.2017.8227450>
- Mohammed, N. A., Abed, M. H., & Albu-Salih, A. T. (2022). Convolutional neural network for color images classification. *Bulletin of Electrical Engineering and Informatics*, 11(3), 1343–1349. <https://doi.org/10.11591/eei.v11i3.3730>
- Nabila, M., Idmayanti, R., & Rahmayuni, I. (2021). Deteksi Wajah Bermasker Menggunakan Webcam dan AWS EC2 Berbasis Raspberry Pi. *JITSI : Jurnal Ilmiah Teknologi Sistem Informasi*, 2(4), 124–133. <https://doi.org/10.30630/jitsi.2.4.54>
- Oza, P., Sharma, P., Patel, S., Adedoyin, F., & Bruno, A. (2022). Image Augmentation Techniques for Mammogram Analysis. *Journal of Imaging*, 8(5), 1–22.
<https://doi.org/10.3390/jimaging8050141>
- Rahayu, W., & Wahyudi, E. (2017). Classical Test Theory of Innappropriate Index Score'S Accuracy Comparison Using Confusion Matrix Accuracy Proportion in Educational Measurement. *Ijer - Indonesian Journal of Educational Review*, 4(1), 84.
<https://doi.org/10.21009/ijer.04.01.08>

- Rochmawati, N., Hidayati, H. B., Yamasari, Y., Tjahyaningtijas, H. P. A., Yustanti, W., & Prihanto, A. (2021). Analisa Learning Rate dan Batch Size pada Klasifikasi Covid Menggunakan Deep Learning dengan Optimizer Adam. *Journal of Information Engineering and Educational Technology*, 5(2), 44–48.
<https://doi.org/10.26740/jieet.v5n2.p44-48>
- S, A. K., & AsstProfMGokilavani, student. (2019). A Study of Medical Image Processing and Segmentation Methods for. *Medical Image Analysis. IJIRAE::International Journal of Innovative Research in Advanced Engineering*, 10(10), 609–615.
<https://doi.org/10.26562/IJIRAE.2019.OCAE10082>
- Syahid, M. F. (2021). *Implementasi deep learning vgg16 dengan transfer learning pada deteksi penyakit tanaman singkong*.
https://repository.uinjkt.ac.id/dspace/bitstream/123456789/65121/1/MUHAMMAD_FIKRI_SYAHID-FST.pdf
- van Ruitenbeek, R. E., & Bhulai, S. (2022). Convolutional Neural Networks for vehicle damage detection. *Machine Learning with Applications*, 9(April), 100332.
<https://doi.org/10.1016/j.mlwa.2022.100332>