

BAB II

TINJAUAN PUSTAKA

2.1 Penelitian Terdahulu

Pada penelitian sebelumnya yang berjudul “*Convolutional Neural Networks for vehicle damage detection*” yang dilakukan oleh (van Ruitenbeek & Bhulai, 2022) menggunakan Convolutional Neural Networks (CNNs) untuk mendeteksi kerusakan pada kendaraan dalam konteks layanan mobilitas bersama. Penelitian ini mengevaluasi berbagai algoritma deep learning, strategi transfer learning, dan teknik pelatihan untuk mengoptimalkan kinerja deteksi. Hasilnya menunjukkan bahwa model akhir, terlatih dengan dataset besar, mampu mendeteksi kerusakan kecil dengan akurat dalam berbagai kondisi. Studi ini juga menyoroti tantangan dalam kinerja deteksi akibat pantulan cahaya yang kuat. Model yang terbaik adalah FSSD dengan Darknet-53 dan YOLO v3 dengan Darknet-53, yang menunjukkan hasil yang menjanjikan dalam mendeteksi dan mengklasifikasikan kerusakan kendaraan, dengan kinerja yang sebanding dengan ahli di bidangnya. Namun, model tersebut dipengaruhi oleh pantulan cahaya yang kuat dan mengalami kesulitan dalam membedakan latar belakang dan kerusakan dalam kondisi tertentu. Kesimpulannya, penelitian ini menunjukkan bahwa deep learning dapat mencapai kinerja yang sebanding dengan manusia dalam deteksi kerusakan kendaraan, namun perlu penelitian lebih lanjut untuk meningkatkan ketangguhan dan konsistensi anotasi. Namun, tidak ada disebutkan informasi spesifik mengenai akurasi persentase yang dicapai oleh model dalam penelitian tersebut.


2.2 Deep Learning

Deep learning merupakan salah satu cabang dari machine learning yang memanfaatkan struktur model komputasi dengan lapisan-lapisan pemrosesan untuk menyajikan representasi data pada berbagai tingkat abstraksi. Metode deep learning ini telah dikembangkan untuk berbagai macam tujuan, seperti mampu mendeteksi objek pada video, identifikasi objek dalam citra, klasifikasi jenis suara, bahkan dalam identifikasi jenis obat-obatan. Kemajuan deep learning memungkinkan untuk menangani data dalam jumlah besar, dimana algoritma backpropagation mampu membimbing mesin untuk menyesuaikan parameter internalnya guna menciptakan representasi pada setiap lapisan berdasarkan informasi dari lapisan sebelumnya.

Dengan penerapan arsitektur deep learning yang tepat, data yang melimpah dan kompleksitas tinggi dapat diolah secara efisien. Di samping itu, deep learning juga berguna dalam pembuatan aplikasi seperti analisis sentimen, penerjemahan bahasa, dan berbagai jenis klasifikasi yang menghasilkan hasil yang tepat. Algoritma deep learning ini juga cocok untuk menangani berbagai jenis masalah, baik yang bersifat supervised, unsupervised, maupun Semi-Supervised Learning, tergantung pada karakteristik dari data yang dihadapi (LeCun et al., 2015).

2.3 Convolutional Neural Network (CNN)

Pada umumnya, *Convolutional Neural Network* (CNN) adalah bagian penting dari jaringan saraf tiruan yang digunakan untuk identifikasi atau klasifikasi objek dalam citra gambar. Komponen utama dalam CNN, yaitu input layer, hidden layers, dan output layer, memiliki peranan krusial dalam proses analisis. Setiap node dalam CNN akan menerima informasi dari input layer, lalu hasilnya diproses melalui hidden layers untuk menghasilkan output. Pengolahan gambar sebagai data melibatkan serangkaian hidden layer dalam CNN, yang bertanggung jawab atas ekstraksi fitur dari gambar untuk kemudian dihitung kemampuan atau performanya (Kadri et al., 2019).



Gambar 2. 1 Struktur Proses Algoritma CNN

Proses pada *Convolutional Neural Network* (CNN), seperti yang terlihat dalam gambar 2.1, melibatkan beberapa tahapan. Tahap awal terdiri dari dua lapisan, yaitu convolutional layers dan pooling layers. Setiap bagian pada convolutional layer diatur berdasarkan feature maps, di mana setiap bagian terhubung ke feature maps pada layer sebelumnya dan mengatur ulang bobot (filter) untuk lapisan selanjutnya.

Convolutional layer didukung oleh fungsi aktivasi, salah satunya adalah algoritma ReLU (*Rectified Linear Unit*). Penggunaan ReLU memiliki kecepatan dalam menjalankan proses, yang membuatnya lebih efisien dalam proses training dan testing. Selain *convolutional* dan *pooling layers*, terdapat juga *fully connected layer*, yang

merupakan bagian dari struktur *Multi-layer Perceptron* (MLP). Layer ini juga menggunakan algoritma ReLU. Fungsi *softmax* digunakan untuk menampilkan hasil akurasi berdasarkan probabilitas dari setiap kelas.

Proses dalam CNN juga melibatkan optimasi, yang bertujuan untuk meningkatkan efisiensi komputasi dari segi waktu dan memori. Metode optimasi seperti Adam dapat digunakan untuk mengatasi jumlah data dan parameter yang besar. Dua parameter utama dalam metode optimasi Adam adalah bobot dan fungsi kerugian (Dendi Maysanjaya, 2020).

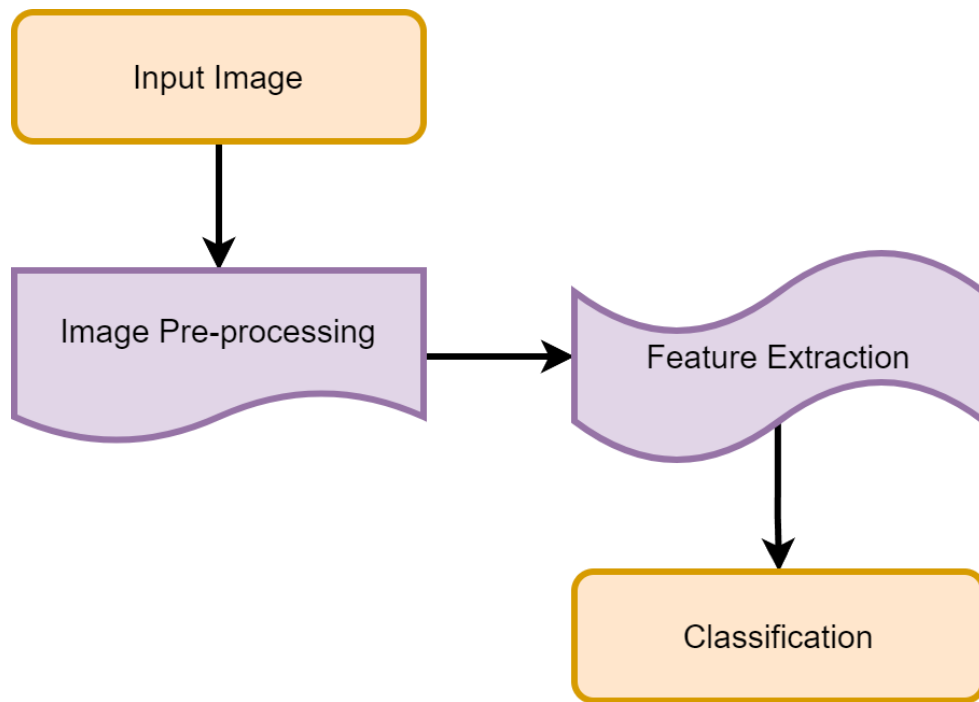
2.4 Confusion Matrix

Confusion Matrix adalah model yang sering digunakan untuk menampilkan hasil pengklasifikasian dengan jelas. Ini juga berperan dalam mengevaluasi kinerja berbagai model algoritma. *Confusion matrix* terdiri dari beberapa parameter untuk mengatur kinerja model, seperti F1-Score, Accuracy, Recall, dan Precision (Rahayu & Wahyudi, 2017).

Dalam perhitungan evaluasi kinerja model seperti F1-Score, Accuracy, Recall, dan Precision, terdapat dua parameter utama, yaitu *False Negative* (FN) dan *False Positive* (FP). *False Negative* terjadi ketika sistem mengidentifikasi suatu kelas sebagai negatif, padahal seharusnya kelas tersebut positif. Sebaliknya, *False Positive* terjadi ketika sistem mengidentifikasi suatu kelas sebagai positif, tetapi seharusnya kelas tersebut negatif (Azhari et al., 2021). Parameter ini penting dalam mengevaluasi kinerja model.

2.5 Image Preprocessing

Image processing adalah metode yang mengubah citra menjadi komputasi algoritma komputer, memungkinkan komputer untuk memperoleh informasi yang terkandung dalam citra melalui proses *feature extraction* (S & AsstProfMGokilavani, 2019). Proses teknik *image preprocessing* melibatkan beberapa langkah, sebagaimana diilustrasikan pada Gambar 2.2.



Gambar 2. 2 Proses *Image Preprocessing*

Langkah-langkah Teknik *Image Processing*:

1. Memasukkan Citra

Citra yang akan diproses dimasukkan ke dalam sistem, dapat berasal dari proses scanner atau hasil pemotretan langsung.

2. Analisis dan Manipulasi Citra

Proses ini meliputi berbagai tahapan seperti peningkatan kualitas pada citra, kompresi data citra, dan perancangan pola citra. Pada tahap ini, citra dianalisis dan dimanipulasi untuk meningkatkan kualitasnya atau mengurangi ukuran file agar lebih efisien.

3. Image Pre-processing

Setelah tahapan analisis dan manipulasi citra, dilakukan proses *image pre-processing*. Data citra yang telah melalui tahap ini akan diubah kembali menjadi gambar yang siap digunakan dalam proses klasifikasi atau analisis lebih lanjut.

2.6 Bak Dump Truk

Bak dump truk adalah bagian dari truk yang berfungsi sebagai tempat untuk mengangkut material, biasanya material berupa batu, tanah, pasir, atau material lain dalam jumlah besar. Bak dump truk dirancang memiliki kemampuan untuk memuat

muatan dalam jumlah besar dan kemudian dapat dengan mudah dimuat atau diturunkan menggunakan mekanisme hidrolik.

Ciri khas utama dari bak dump truk adalah kemampuannya untuk mengangkat bak menjadi miring ke belakang untuk membongkar muatan. Ini dilakukan dengan menggunakan sistem hidrolik yang mengontrol bagian belakang truk untuk naik dan membuka bak, memungkinkan muatan untuk tumpah keluar ke tempat tujuan seperti gudang atau area konstruksi.

Dump truk memiliki beberapa jenis bak, termasuk bak terbuka dan bak tertutup. Bak terbuka lebih umum digunakan untuk mengangkut material-material yang tidak memerlukan perlindungan terhadap cuaca, seperti tanah atau batu. Sementara itu, bak tertutup biasanya digunakan untuk material yang perlu dilindungi dari elemen-elemen eksternal, seperti bahan kimia atau material yang mudah rusak karena cuaca.

Bak dump truk sering digunakan pada industri konstruksi, pertambangan, pengelolaan limbah, dan sektor transportasi dalam mengangkut material dalam jumlah besar dengan efisiensi yang tinggi. Keberadaannya sangat penting dalam operasi konstruksi dan pemindahan material dalam skala besar.

2.7 *Tensorflow*

TensorFlow adalah sebuah library yang digunakan dalam bidang machine learning sebagai platform end-to-end. Framework ini merupakan library yang luas dan fleksibel. Salah satu fitur utama yang sering dimanfaatkan dari *TensorFlow* adalah penggunaan algoritma *Convolutional Neural Network* (CNN) dalam pengolahan data citra. Selain itu, *TensorFlow* juga terkenal karena mampu untuk berjalan pada berbagai platform tanpa mengorbankan performa dan kecepatan yang signifikan.

TensorFlow dikenal sebagai framework generasi kedua yang dikembangkan dan digunakan secara luas di Google. Pada tanggal 11 Februari, versi 1.0.0 dari *TensorFlow* dirilis, menandai tonggak penting dalam perkembangannya. Salah satu keunggulan dari *TensorFlow* adalah kemampuannya untuk berjalan di berbagai *Central Processing Unit* (CPU) serta menggunakan *Graphics Processing Unit* (GPU) dengan dukungan ekstensi seperti *Compute Unified Device Architecture* (CUDA) dan opsi SYCL pada unit grafis. Hal ini memungkinkan penggunaan GPU untuk melakukan komputasi umum, meningkatkan kecepatan dan efisiensi proses komputasi pada *TensorFlow* (Nabila et al., 2021).

2.8 Keras

Keras adalah library pemrosesan jaringan saraf yang sangat populer dan mudah digunakan dalam bahasa pemrograman Python. Di Keras, pengguna dapat dengan mudah membuat, melatih, dan mengevaluasi model jaringan saraf dengan sedikit kode. Library ini menekankan kesederhanaan dan modularitas, memungkinkan pengguna dengan cepat membuat model jaringan saraf dengan berbagai arsitektur, termasuk jaringan saraf konvolusional (CNN). Salah satu keunggulan Keras adalah tingginya tingkat abstraksi yang dibawanya ke jaringan saraf. (Rochmawati et al., 2021)

Keras memberikan kemudahan dalam membuat model jaringan saraf dengan tingkat kompleksitas yang rendah, cocok untuk pemula yang ingin mempelajari dan memahami konsep dasar pemodelan jaringan saraf. Selain itu, Keras mendukung banyak lapisan, fungsi aktivasi, pengoptimal, dan metrik evaluasi yang memudahkan pengujian konfigurasi model yang berbeda. Kemudahan penggunaan dan fleksibilitas Keras menjadikannya pilihan utama bagi banyak praktisi yang mengimplementasikan jaringan saraf, terutama dalam pemrosesan gambar dan tugas pembelajaran mendalam lainnya.

2.9 VGG16

VGG16 adalah arsitektur jaringan saraf konvolusi (CNN) yang terdiri dari 16 lapisan, termasuk lapisan konvolusi 3x3, diikuti oleh lapisan max-pooling dan beberapa lapisan yang terhubung sepenuhnya. Dikembangkan oleh *Visual Graphics Group* (VGG) Universitas Oxford, arsitektur ini dikenal karena kedalaman dan kesederhanaannya. VGG16 dapat mengekstrak fitur gambar secara bertahap pada abstraksi tingkat tinggi menggunakan sejumlah besar lapisan, memungkinkan Anda mengidentifikasi pola dan fitur kompleks dari gambar. (Syahid, 2021)

Keuntungan utama VGG16 adalah dapat dilatih pada kumpulan data besar seperti ImageNet, dan dengan melakukan penyesuaian di akhir jaringan, VGG16 dapat digunakan sebagai model terlatih untuk berbagai tugas klasifikasi gambar. Namun, kompleksitasnya yang tinggi juga berarti bahwa VGG16 memerlukan sumber daya komputasi dalam jumlah besar, sehingga dapat memperlambat proses pelatihan dan prediksi. Namun demikian, ini adalah salah satu arsitektur paling populer di dunia jaringan saraf konvolusional karena kegunaannya dalam pemrosesan gambar dan pembelajaran transfer.